Ouvidoria Inteligente: triagem semântica de manifestações cidadãs

Relatório técnico · Processamento de Linguagem Natural / Engenharia de IA · Representações vetoriais, busca semântica e chunking

Autoria: _____ · Setembro de 2026

1. Visão geral e decisões de projeto

O objetivo foi construir um protótipo que substitua a triagem por palavras-chave da Ouvidoria por uma triagem **semântica**, capaz de (i) reconhecer duplicatas escritas com palavras diferentes, (ii) agrupar temas relacionados e (iii) tratar manifestações longas sem perder contexto. Como o arquivo original não estava disponível, foi construída uma base **sintética** de 40 manifestações seguindo exatamente a especificação: 8 por categoria, textos de 111 a 714 caracteres, 5 textos longos (>500 caracteres), **6 pares de duplicatas** (15% das manifestações) e os pares citados no enunciado (M003×M017, M008×M022, M008×M031). O gabarito fica num arquivo separado (*duplicatas_gabarito.json*), para manter intacto o esquema oficial de 4 campos. Ele inclui também 6 “falsos amigos” (mesmo tipo de problema em locais diferentes) para medir falsos positivos.

Toda a lógica (carregamento, embeddings, similaridade, *detectar_duplicatas*, chunking e projeções) está em **ouvidoria_core.py**, compartilhado pelos três notebooks e pelo app, o que garante que os números sejam os mesmos em todos. Foram comparados três modelos do *sentence-transformers*: **MiniLM** (paraphrase-multilingual-MiniLM-L12-v2, 384 dim.), **MPNet** (paraphrase-multilingual-mpnet-base-v2, 768 dim.) e **E5-small** (intfloat/multilingual-e5-small, com prefixo “query: ”). O BAAI/bge-small-pt-v1.5 sugerido não está publicado no Hugging Face Hub (a API retorna 401), por isso foi substituído pelo E5.

2. Entrega 1: representações esparsas × densas

Par	BoW	TF-IDF	TF-IDF char 3-5	MiniLM	MPNet	E5-small
M003×M017 (duplicata)	0,059	0,041	0,081	0,711	0,762	0,920
M008×M022 (duplicata)	0,184	0,136	0,109	0,818	0,810	0,934
M008×M031 (sem relação)	0,000	0,000	0,022	0,206	0,297	0,892
AUC duplicata × resto (780 pares)	0,921	0,956	0,907	1,000	1,000	0,999

Tabela 1. Cosseno nos pares do enunciado e AUC-ROC de separação das 6 duplicatas reais.

- **Esparsas medem sobreposição lexical.** O mesmo buraco (“buraco enorme / Av. Brasil / padaria” × “asfalto esburacado / avenida principal / panificadora”) compartilha um único termo (“vai”) e fica com cosseno de 0,06. O pouco que M008×M022 pontua vem do endereço (“jose”), e não do problema. N-gramas de caracteres não resolvem, porque a dificuldade é de **sinônimos**, e não de morfologia. A AUC razoável das esparsas vem de 4 das 6 duplicatas repetirem o nome do local.
- **Embeddings aproximam paráfrases** (0,71–0,82 nas duplicatas contra 0,21–0,30 no controle com MiniLM/MPNet; AUC ≈ 1,0).
- **A escala do cosseno depende do modelo.** O E5 é anisotrópico: 769 dos 780 pares ficam acima de 0,85, e o controle negativo (0,89) está no percentil 74. Ele *ordena* tão bem quanto os outros, mas o valor absoluto não é comparável. Por isso limiares precisam ser calibrados por modelo.
- Remover stopwords zera a similaridade espúria do controle negativo no BoW (0,122 → 0,000).

3. Entrega 2: detecção de duplicatas

A função *detectar_duplicatas(textos, limiar=0.85)* devolve todos os pares i<j com cosseno ≥ limiar (e aceita embeddings pré-calculados). **Com o limiar padrão de 0,85 o MiniLM não encontra nenhuma das 6 duplicatas**, e isso motivou a calibração. Foram comparadas quatro estratégias de limiar:

Estratégia (MPNet)	Limiar	VP	FP	FN	F1	Observação
Fixo 0,85 (enunciado)	0,850	1	0	5	0,29	Perde 5 de 6; no E5 marca 769 pares
Percentil 90	0,542	6	72	0	0,14	Duplicatas são 0,77% dos pares, não 10%
Percentil pela taxa esperada (99,2)	0,736	6	0	0	1,00	F1 ≥ 0,83 nos 3 modelos, sem gabarito
Escolhido: meio da margem	**0,750**	**6**	**0**	**0**	**1,00**	Margem 0,736–0,762

Tabela 2. Estratégias de limiar para o MPNet (resultados dos três modelos no notebook).

Decisão: MPNet com limiar 0,75. É o único modelo com **margem positiva**: a duplicata mais fraca (M003×M017, 0,762) fica acima do não-duplicado mais forte (M005×M031, 0,736). No MiniLM e no E5 a margem é negativa. O limiar

dinâmico sugerido nas dicas funciona desde que o percentil venha da **taxa esperada de duplicatas entre pares**, que cai com o quadrado do número de manifestações (com 4.000/mês, um p90 marcaria ~800 mil pares). Ressalva: o valor foi ajustado com apenas 6 positivos, e a margem é de 0,03.

Falsos positivos (em limiares vizinhos) são sobretudo o *mesmo tipo de problema em outro local* (iluminação na Rua das Acácias × praça da Matriz), *consequências parecidas* ("moradores com medo à noite" por falta de luz × por tráfico) e *textos longos com subtemas* (obra com buracos × buraco que volta com a chuva). **Falsos negativos** ocorrem quando o cidadão acrescenta um fato novo (M026 cita um assalto) ou omite o local (M017 não diz "Av. Brasil"). Conclusão: embeddings medem **semelhança de assunto**, e não identidade do caso. Por isso propomos uma **triagem em duas faixas**: ≥ 0,75 sugere vínculo automático; 0,65–0,75 vai para revisão humana (11 pares, 1,4% do total). Uma evolução natural é somar um sinal de localização (NER de endereço).

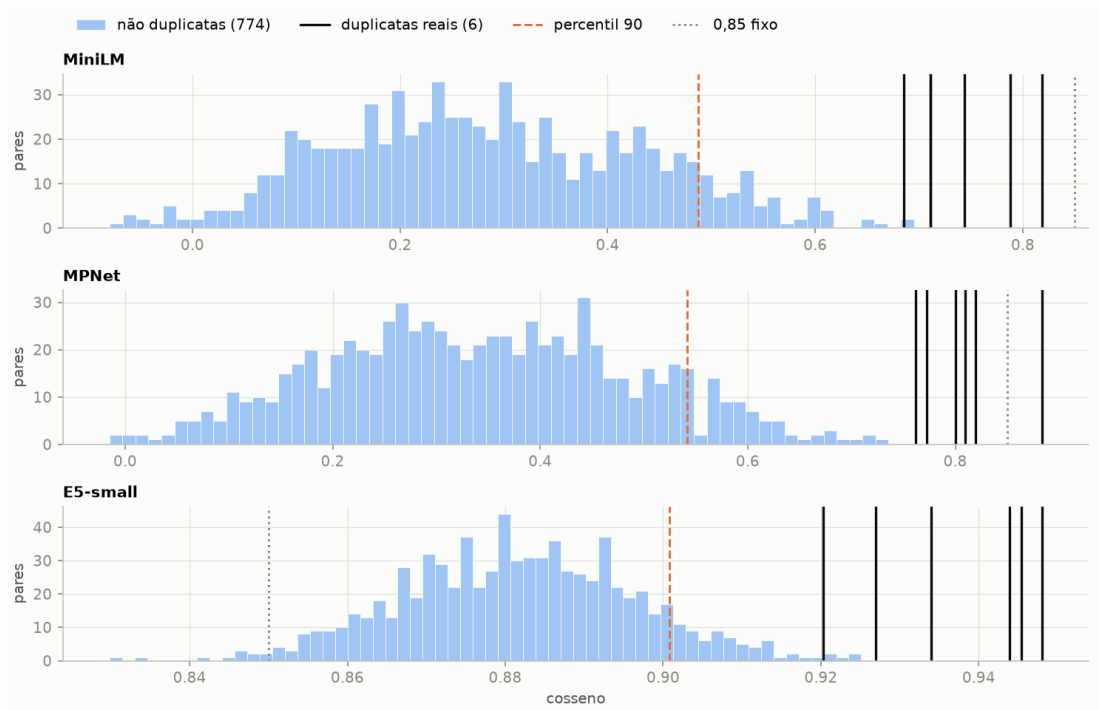


Figura 1. Distribuição dos cossenos dos 774 pares não duplicados (azul) e das 6 duplicatas reais (linhas pretas). O p90 e o 0,85 fixo caem em lugares muito diferentes em cada modelo.

4. Entrega 3: chunking de manifestações longas

Achado central: MiniLM e MPNet leem no máximo **128 tokens**, e as 5 manifestações longas têm 156–186. O *sentence-transformers* trunca em silêncio: **20–34% do texto é ignorado**, e o cosseno entre o embedding do texto inteiro e o do texto sem o final é 1,0000. O estacionamento sem vigia da UPA (M006) e o pedido de câmeras (M034), por exemplo, eram invisíveis para a busca. Foram testadas configurações do *RecursiveCharacterTextSplitter*:

Config (size, overlap)	Chunks	Termina em fim de frase	Coesão vizinhos	Silhueta	Alvo em 1º (busca)
A (300, 0)	15	100%	0,47	0,17	3 de 5
B (300, 80)	16	100%	0,54	0,21	3 de 5
C (120, 40)	46	74%	0,27	0,05	**5 de 5**
Controle (200, 0) = (200, 50)	25	100%	0,32	0,09	—
Fixo sem separadores (200, 50)	25	20%	0,49	0,14	—

Tabela 3. Métricas por configuração (MiniLM). Documento inteiro: alvo em 1º em só 2 de 5 consultas (o estacionamento do M006 ficava em 31º).

- **Overlap × coesão.** O overlap eleva a coesão entre chunks vizinhos (A→B: 0,47→0,54; 120/0→120/40: 0,23→0,27). Mas no splitter recursivo ele é feito com **unidades inteiras** (frases/orações), e não com caracteres: como 94% das frases têm mais de 50 caracteres, (200, 0) e (200, 50) geraram **chunks idênticos**. Coesão alta também pode ser redundância: o corte fixo repete 50 caracteres e quebra palavras ("disseram q" | "ete horas").
- **Qual preserva melhor o sentido?** Como unidade de denúncia, a **B (300, 80)**: frases completas, 1–3 fatos por chunk, maior silhueta. Para achar um fato específico, a C (120, 40), que colocou os 5 alvos em 1º mas gera fragmentos sem sujeito. Recomendamos o padrão **small-to-big**: buscar em chunks pequenos e exibir o contexto maior. É o que o app faz.

- **Chunks no 2D.** Na B, os chunks de cada manifestação ficam em torno do documento inteiro no t-SNE; na C eles se espalham. 3 de 16 chunks da B têm como vizinho mais próximo uma manifestação de **outra categoria** (os postes apagados do M034 → iluminação; o córrego que invade as ruas do M024 → buraco com chuva). Uma manifestação longa pode conter mais de uma demanda.

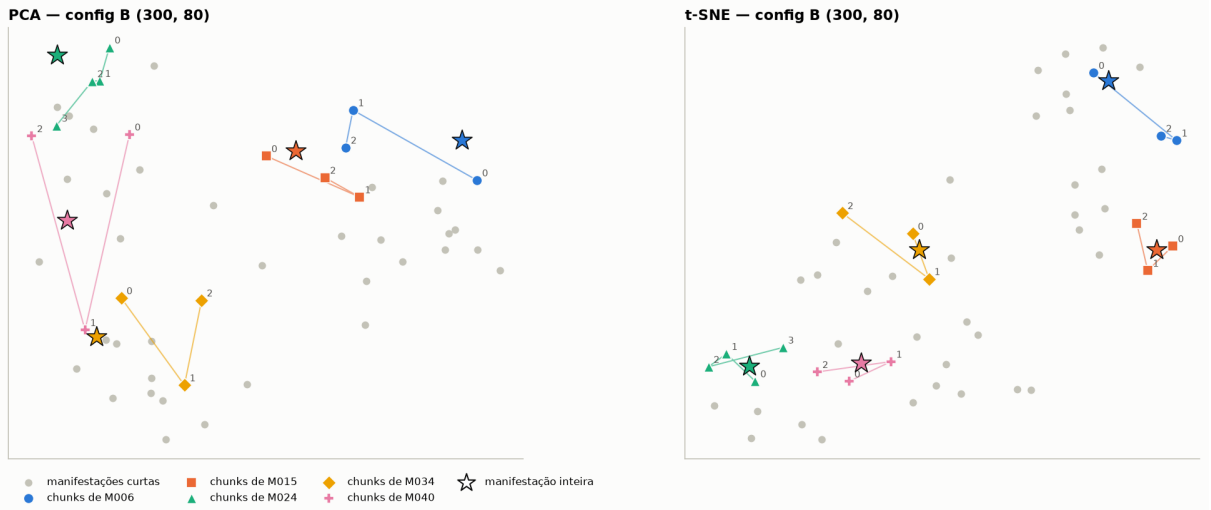


Figura 2. Chunks da configuração B (linhas ligam chunks consecutivos; estrelas = manifestação inteira; cinza = manifestações curtas), em PCA e t-SNE.

5. Entrega 4: aplicação Streamlit

O **app_ouvidoria.py** (*streamlit run app_ouvidoria.py*) tem sidebar com seleção de modelo, top-k, faixas de cor e parâmetros de indexação, e usa *st.cache_resource* para o modelo e *st.cache_data* para os embeddings. As quatro abas:

- **Busca Semântica:** exemplos clicáveis; top-k com score e faixa verde/amarela/vermelha (>0,7, >0,5, demais), indicada por cor, ícone e valor; **aviso de possível duplicata** quando o 1º resultado passa do limiar calibrado; manifestações longas indexadas por chunks (score = máximo), com o **trecho que casou destacado**; histograma mostrando se os resultados se destacam do resto da base.
- **Base Completa:** métricas, filtros por categoria e palavra-chave (para contrastar com a busca semântica), botão que gera a matriz de similaridade interativa, lista de pares com limiar ajustável, precisão/revocação contra o gabarito e download em CSV.
- **Espaço Vetorial:** PCA/t-SNE, cor por categoria ou cluster K-Means (e símbolo sempre por categoria), linhas ligando as duplicatas, a última busca plotada no mapa, ARI, silhueta, tabela cluster×categoria e o comentário pedido. Os clusters coincidem **só em parte** (ARI ≈ 0,40): educação e saúde formam grupos quase puros; infraestrutura, segurança e meio ambiente se misturam, porque o cidadão descreve a *consequência* (“rua escura = medo”) e não a secretaria responsável.
- **Chunking:** carrega uma manifestação longa ou aceita texto livre; três estratégias; mostra chunks com o overlap destacado, tokens contra o limite do modelo, coesão, vizinho mais próximo na base, projeção 2D sobre a base, matriz chunk×chunk e os embeddings (tabela, mapa de dimensões e CSV).

6. Dificuldades e aprendizados

- **Limiar não é universal.** O 0,85 do enunciado não serve para nenhum dos três modelos. Aprendemos a calibrar pela distribuição (margem, taxa esperada) e a desconfiar de valores absolutos de cosseno ao trocar de modelo.
- **Truncamento silencioso.** Só foi descoberto ao comparar embeddings do texto inteiro e do texto cortado. É o argumento mais concreto a favor do chunking, e não aparece em mensagem de erro nenhuma.
- **Overlap não é o que parece.** O comportamento do splitter recursivo (overlap por unidades) só apareceu no experimento de controle. Parâmetros de chunking devem ser escolhidos olhando o tamanho das frases do corpus.
- **Assunto ≠ caso.** Os erros de duplicata e a discordância cluster×categoria têm a mesma raiz: embeddings capturam o tema, enquanto a gestão precisa de local e responsável. A solução é combinar sinais, e não trocar de modelo.
- **Limitações:** base sintética e pequena (6 positivos); limiares ajustados nos mesmos dados; resultados com dados reais podem ser diferentes. Próximos passos: validar com amostra rotulada real, extração de endereço, classificador supervisionado sobre os embeddings para roteamento e índice vetorial (FAISS) para escala.

Referências. *Reimers & Gurevych (2019), Sentence-BERT; Wang et al. (2024), Multilingual E5; documentação sentence-transformers (sbert.net) e LangChain Text Splitters.*